

Classificação de Sinais de Trânsito (GTSRB)

Data Augmentation e Ensembles de Redes de *Deep Learning*

Visão Computacional e Processamento de Imagem (VCPI)

Trabalho Prático 1 — Fases 1 e 2

Junho de 2026

Resumo

Este trabalho explora modelos de *deep learning* para a classificação de sinais de trânsito no dataset alemão **GTSRB** (43 classes), com o objetivo de maximizar a *accuracy* no conjunto de teste. Na **Fase 1** treinamos 14 modelos (7 estratégias de *data augmentation* $\times$ 2 arquiteturas) mais 3 ablações, isolando o efeito de cada técnica de processamento de imagem; o melhor modelo individual foi a **ResNet18** a 224×224 com pré-processamento CLAHE, atingindo **99,52%**. Na **Fase 2** combinamos os 17 modelos resultantes num *ensemble* por *soft voting*, chegando a **99,80%** — ao nível do melhor resultado publicado para o GTSRB ($\sim 99,82\%$).

Índice

1	Introdução	1
2	Análise Exploratória	1
3	Fase 1 — Pré-processamento e <i>Data Augmentation</i>	2
3.1	Filtros clássicos e CLAHE	2
3.2	As 7 estratégias de <i>augmentation</i>	2
3.3	Arquiteturas	3
3.4	Resultados	3
3.5	Ablações adicionais	4
3.6	Conclusões da Fase 1	5
4	Fase 2 — Ensembles	5
4.1	<i>Pool</i> de modelos e infraestrutura	5
4.2	Métodos de agregação	5
4.3	Resultados	5
4.4	Quantos modelos são precisos? (sem <i>cherry-picking</i>)	6
4.5	<i>Track leakage</i>	6
4.6	Conclusões da Fase 2	7
5	Conclusão Global	7

1 Introdução

O **German Traffic Sign Recognition Benchmark** (GTSRB) é um *dataset* de referência com mais de 50 000 imagens de sinais de trânsito reais, distribuídas por **43 classes**. As imagens têm resoluções variáveis (de ~ 15 a ~ 250 px), condições de iluminação heterogêneas, oclusões parciais e desfoque de movimento, o que o torna um banco de ensaio realista para técnicas de processamento de imagem e classificação. O melhor resultado publicado situa-se em **99,82%** (Cireşan *et al.*, 2012, obtido com um comitê/*ensemble* de 25 redes), acima do desempenho humano reportado ($\sim 98,8\%$).

O trabalho divide-se em duas fases:

- **Fase 1 — *Data augmentation*.** Treinar vários modelos com estratégias de *augmentation* diferentes (em pré-processamento e dinâmico), explorar filtros clássicos de processamento de imagem e avaliar o seu impacto no desempenho final.
- **Fase 2 — *Ensembles*.** Estudar o potencial de combinar as redes treinadas na Fase 1 num *ensemble*, comparando métodos de agregação.

Todo o trabalho está reunido num único *notebook* (`notebook.ipynb`); este relatório descreve as opções tomadas e analisa os resultados.

2 Análise Exploratória

Antes de treinar, caracterizámos o *dataset*:

- **Desbalanceamento de classes.** As classes têm contagens muito desiguais (de algumas centenas a vários milhares de exemplos). Isto motivou um *split* estratificado e uma ablação posterior com `WeightedRandomSampler`.
- **Resoluções pequenas e variáveis.** A mediana das imagens originais ronda os ~ 40 px; cerca de metade são menores que 48×48 . Esta observação foi determinante na escolha da resolução de entrada (Secção 3.5).
- ***Track leakage*.** O GTSRB é construído a partir de *tracks* — sequências de 30 fotogramas do mesmo sinal físico. Imagens do mesmo *track* são quase idênticas. Um *split* aleatório coloca fotogramas do mesmo sinal em treino e validação ao mesmo tempo, tornando a validação demasiado otimista. Este fenómeno foi identificado na Fase 1 (praticamente todos os modelos saturam a $\sim 100\%$ em validação) e teve consequências metodológicas na Fase 2.

O *split* treino/validação foi **estratificado a 85/15**, preservando a proporção de cada classe; o conjunto de teste oficial (12 630 imagens) foi mantido intacto e usado apenas para avaliação final.

3 Fase 1 — Pré-processamento e *Data Augmentation*

3.1 Filtros clássicos e CLAHE

Comparámos visualmente vários filtros clássicos de processamento de imagem (equalização global de histograma, *sharpen*, *blur* gaussiano e **CLAHE**). O **CLAHE** (*Contrast Limited Adaptive Histogram Equalization*) destacou-se: ao equalizar o histograma *localmente* (por blocos), com um limite de *clip* que evita amplificar ruído, normaliza a luminância sem destruir detalhe. Aplicámo-lo no canal de luminância (espaço LAB) com `clip_limit=2.0` e *tiles* de 4×4 . Como é um passo

determinístico de pré-processamento, foi aplicado de forma coerente em treino, validação e teste sempre que usado.

3.2 As 7 estratégias de *augmentation*

Definimos 7 estratégias de complexidade **crescente**, de forma a isolar o efeito de cada componente (desenho incremental tipo ablação):

Estratégia	Componentes (acumulados)	Tipo
A_baseline	só <i>Resize</i> + <i>Normalize</i> (controle)	—
B_geo_light	+ <i>RandomAffine</i> leve (rot. $\pm 10^\circ$, transl.)	geométrico
C_geo_heavy	+ <i>scale</i> , <i>shear</i> , <i>RandomPerspective</i>	geométrico
D_photo	+ <i>ColorJitter</i> (brilho/contraste/sat./hue)	fotométrico
E_combo	C + D + <i>RandomGaussianBlur</i>	combinado
F_clahe_combo	E precedido de CLAHE	+ pré-proc.
G_full	F + <i>RandomErasing</i> (<i>cutout</i>)	+ regularização

Tabela 1: Estratégias de *data augmentation*. Cada uma acrescenta uma técnica à anterior, permitindo atribuir as variações de desempenho a componentes específicos.

Decisões de domínio. Deliberadamente *não* usamos *RandomHorizontalFlip* — inverteria sinais direcionais (p.ex. “virar à direita” $\rightarrow$ “virar à esquerda”) e sinais com texto, gerando rótulos errados. As rotações foram limitadas a $\pm 15^\circ$ para não confundir orientações. Na estratégia F, o *jitter* fotométrico foi suavizado porque o CLAHE já normaliza a luminância (redundância evitada).

3.3 Arquiteturas

Comparámos duas arquiteturas:

- **Conv_VCPI** — CNN própria estilo VGG: 3 blocos (*conv* 3×3 + *BatchNorm* + *ReLU*, $\times 2$) com *MaxPool* e *Dropout* crescente em profundidade, seguidos de *Global Average Pooling* e uma camada totalmente ligada. ~ 332 k parâmetros. O GAP (em vez de *flatten*) reduz parâmetros e melhora a robustez.
- **ResNet18** — pré-treinada no ImageNet, com a cabeça de classificação substituída para 43 classes (*transfer learning*). ~ 11 M parâmetros.

Setup de treino. Otimizador AdamW ($\text{lr}=10^{-3}$, *weight decay*= 10^{-4}), **CrossEntropyLoss**, *scheduler ReduceLROnPlateau* (fator 0,5, paciência 3 sobre a *val_loss*), *early stopping* (paciência 7), *mixed precision* em GPU, e *seed* fixa por experiência para reprodutibilidade. O *checkpoint* guardado é o de *melhor val_loss* (não o da última época), e a avaliação final é feita com esse. A resolução base foi 48×48 .

3.4 Resultados




Figura 1: Test accuracy por estratégia e arquitetura (resolução base 48×48). A tendência geral é $A < D \approx B < C < E < F \approx G$.

Arquitetura	Estratégia	Test acc. (%)	Best val (%)	Épocas
Conv_VCPi	F_clahe_combo	99.48	99.92	30
Conv_VCPi	G_full	99.43	99.94	30
ResNet18	G_full	99.26	99.94	23
Conv_VCPi	E_combo	99.22	99.96	30
ResNet18	E_combo	99.10	99.94	30
Conv_VCPi	C_geo_heavy	98.98	99.96	30
ResNet18	F_clahe_combo	98.98	99.96	30
Conv_VCPi	B_geo_light	98.95	99.98	30
Conv_VCPi	A_baseline	98.76	100.0	28
ResNet18	C_geo_heavy	98.75	99.92	26
Conv_VCPi	D_photo	98.68	99.96	30
ResNet18	B_geo_light	98.45	100.0	30
ResNet18	A_baseline	98.16	99.94	26
ResNet18	D_photo	98.16	99.79	19

Tabela 2: Resultados dos 14 modelos da Fase 1 (resolução 48×48), ordenados por *test accuracy*. Note-se a saturação da *best val* junto dos 100% — sintoma do *track leakage*.




Figura 2: Curvas de *validation accuracy* dos 14 modelos. A saturação rápida e generalizada perto de 100% confirma o *track leakage*: a validação não discrimina bem entre modelos.

Leitura dos resultados.

1. **O CLAHE traz ganho real:** comparando E com F no Conv_VCPi (única diferença: o CLAHE), a *accuracy* sobe +0,26 pp. Confirma que técnicas *clássicas* de processamento de imagem ainda fazem diferença em *deep learning*.
2. **Geo + foto + CLAHE > qualquer componente isolado:** a combinação supera cada técnica usada sozinha.
3. **O RandomErasing (G) não melhorou** o Conv_VCPi: quando a *augmentation* já é rica, é regularização a mais.
4. **Resultado inesperado:** a 48×48 , a CNN própria (Conv_VCPi, $33\times$ menos parâmetros) *bate* a ResNet18 pré-treinada nas 7 estratégias.

3.5 Ablações adicionais

(a) **WeightedRandomSampler.** Reamostrar para compensar o desbalanceamento *não* melhorou (até piorou ligeiramente) — o *pipeline* já generaliza para classes raras; o desbalanceamento não é o gargalo.

(b) **Resolução 64×64 (Conv_VCPi).** Ficou $-0,10$ pp face a 48×48 , ao dobro do tempo. Como $\sim 50\%$ das imagens originais têm menos de 48 px, subir a resolução é sobretudo *upsampling* sem informação nova. 48×48 é o ponto certo para esta arquitetura.

(c) **Resolução nativa 224×224 (ResNet18).** Esta foi a ablação decisiva. A 48×48 a ResNet18 ficava atrás; a 224×224 (resolução para que o *backbone* ImageNet foi desenhado) saltou para **99,52%**, tornando-se o melhor modelo individual da Fase 1 (+0,54 pp vs 48×48). Os pesos pré-treinados só rendem perto da escala em que foram aprendidos — *transfer learning* não é gratuito, depende do *match* de domínio/resolução. O custo foi $\sim 2,5\times$ o tempo de treino.

3.6 Conclusões da Fase 1

A Fase 1 terminou com **99,52%** (ResNet18 + F_clahe_combo a 224×224), $\sim 0,30$ pp abaixo do SOTA. O CLAHE como pré-processamento, a combinação rica de *augmentation* geométrico e fotométrico, e o *match* de resolução no *transfer learning* foram os fatores de maior impacto. Os erros remanescentes são quase todos por **ambiguidade visual** (sinais triangulares parecidos, limites de velocidade adjacentes, imagens degradadas) — indício de que se está perto do tecto de

um único modelo.

4 Fase 2 — Ensembles

4.1 *Pool* de modelos e infraestrutura

O *pool* reúne os **17 modelos** treinados na Fase 1: as 14 combinações principais (7 estratégias $\times$ 2 arquiteturas) mais 3 ablações (Conv_VCPi a 64×64 , Conv_VCPi com `WeightedSampler`, e ResNet18 a 224×224). Cada modelo é avaliado no conjunto de teste com o seu *próprio* pré-processamento (resolução e CLAHE corretos). Os *logits* de cada modelo são calculados uma vez e guardados em *cache* em disco, pelo que avaliar qualquer combinação passa a ser instantâneo.

4.2 Métodos de agregação

- **Soft voting**: média das probabilidades *softmax* de cada modelo, seguida de *argmax*. Preserva a informação de confiança.
- **Weighted**: média ponderada, cada modelo pesa proporcionalmente à sua *test accuracy* individual.
- **Hard voting**: cada modelo vota na sua classe *argmax*; ganha a mais votada.

4.3 Resultados

Método	Test acc. (%)	Erros / 12 630
Melhor modelo individual (ResNet18 @224)	99.52	61
Ensemble <i>hard</i> (17)	99.76	31
Ensemble <i>weighted</i> (17)	99.79	26
Ensemble <i>soft</i> (17)	99.80	25

Tabela 3: Comparação dos métodos de *ensemble* sobre os 17 modelos. O *soft voting* é o melhor; o *hard voting* perde por descartar a confiança de cada modelo.




Figura 3: *Test accuracy* dos métodos de agregação face ao melhor modelo individual.

4.4 Quantos modelos são precisos? (sem *cherry-picking*)

Em vez de escolher o “melhor subconjunto” (o que enviesaria o resultado se a escolha fosse feita no teste), ordenámos os modelos por *accuracy* individual e medimos a *accuracy* do *ensemble* à medida que adicionamos modelos, do melhor para o pior. A curva mostra a partir de quando o ganho satura.




Figura 4: Accuracy do ensemble (soft voting) em função do número de modelos. O ganho fica a $\leq 0,05$ pp do valor final a partir de ~ 13 modelos: o benefício vem da **diversidade**, não da quantidade.

4.5 Track leakage

Seria tentador selecionar um subconjunto ótimo de modelos usando o conjunto de validação. Isso *não* é viável aqui: por causa do *track leakage*, **todos** os modelos atingem $\sim 100\%$ em validação, pelo que o val *não discrimina*. Confirmámo-lo experimentalmente — uma seleção *greedy* guiada pela validação escolhe modelos arbitrários e produz piores resultados em teste (chegando a $\sim 98,4\%$ nos primeiros passos). Por isso reportamos o *ensemble* de **todos os 17 modelos**, que evita qualquer *cherry-picking* e é a opção metodologicamente honesta.




Figura 5: Matriz de confusão (normalizada por linha) do *ensemble soft voting*. A diagonal é quase perfeita; os poucos erros concentram-se em classes visualmente ambíguas.

4.6 Conclusões da Fase 2

1. O *ensemble* subiu do melhor modelo individual (99,52%) para **99,80%** (+0,28 pp), mesmo com um *soft voting* simples de todos os modelos.
2. **Soft voting > weighted > hard**: agregar probabilidades (preservando confiança) bate o voto maioritário.

3. A *accuracy satura com poucos modelos*: o ganho vem da diversidade (arquiteturas e *augmentations* diferentes erram em imagens diferentes), não do número.
4. **Lição metodológica**: o *track leakage* impediu uma seleção de subconjunto sem viés; um *split track-aware* desde o início permitiria selecionar o *ensemble* de forma rigorosa.

Sobre o SOTA. Os nossos 99,80% estão essencialmente ao nível do melhor resultado publicado (99,82%) — uma diferença de ~ 2 imagens em 12630, dentro do ruído. O próprio SOTA do GTSRB é um *ensemble* (comité de 25 redes).

5 Conclusão Global

A Fase 1 mostrou que o processamento de imagem importa: o **CLAHE** deu ganho medível, a combinação rica de *augmentation* geométrico e fotométrico foi a melhor estratégia, e o *match* de resolução foi decisivo para o *transfer learning* render. Um único modelo chegou a 99,52%. A Fase 2 mostrou que combinar redes *diversas* num *ensemble* por *soft voting* extrai o ganho final, levando o resultado a **99,80%**, ao nível do SOTA. Em ambas as fases privilegiámos uma avaliação *honest* (sem *cherry-picking*), o que consideramos tão importante quanto o número final.

Trabalho futuro. (i) *Split track-aware* para uma validação fiável e seleção rigorosa de subconjuntos; (ii) *Test-Time Augmentation* (TTA) sobre os modelos do *ensemble*; (iii) arquiteturas com transformações espaciais explícitas (*Spatial Transformer Networks*).

Referências

- [1] J. Stallkamp, M. Schlipsing, J. Salmen, C. Igel. *Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition*. Neural Networks, 2012. (GTSRB)
- [2] D. Cireşan, U. Meier, J. Masci, J. Schmidhuber. *Multi-column deep neural network for traffic sign classification*. Neural Networks, 2012. (SOTA, *ensemble* de 25 redes, 99,46–99,82%)
- [3] K. He, X. Zhang, S. Ren, J. Sun. *Deep Residual Learning for Image Recognition*. CVPR, 2016. (ResNet)
- [4] K. Zuiderveld. *Contrast Limited Adaptive Histogram Equalization*. Graphics Gems IV, 1994. (CLAHE)